

Tema 2
Matei Rares-Andrei
315CC

Timp impletentare: 10 ore
Durata rulare checker pe masina personala ~ 27 sec

Rezolvare:

Task 1

Initializez variabila `new_x` si dau cast fotografiei la tipul de date double. Folosesc functia `svd` din octave pentru a obtine matricea diagonala cu valorile singulare (S) si matricile ortogonale U si V a caror coloane reprezinta vectorii singulari stanga, respectiv dreapta ai matricei `photo`. Apoi retin primele k coloane din U si V si retin submatricea formata din primele k linii si coloane din matricea S . Calculez apoi aproximarea imaginii folosind matricile obtinute si retin rezultatul in `new_X`, caruia ii dau cast la `uint8`.

Task 2

Initializez variabila `new_x` si dau cast fotografiei la tipul de date double. Parcurg matricea fotografiei linie cu linie si calculez media pentru fiecare folosind `sum`, urmand apoi sa scad din fiecare element al liniei media obtinuta. Construiesc matricea Z folosind formula data in cerinta si aplic `svd` acesteia. Retin apoi in matricea W primele pcs coloane din V , obtinand astfel spatiul componentelor principale. Calculez apoi matricea Y folosind formula $Y = W^T * photo$, Y fiind proiectia pozei in spatiul obtinut anterior. In final, calculez aproximarea imaginii in variabila `new_X` folosind formula din cerinta si dau cast variabilei la `uint8`.

Task 3

Urmez pasii de la task 2 pana la calculul matricei de covarianza Z pe care o obtin cu formula $Z = photo * photo^T / (n - 1)$, unde n reprezinta numarul de coloane ale matricii imagine. Apoi calculez folosind functia `eig` vectorii proprii (retinuti in matricea v) si valorile proprii (retinute in matricea diagonala S). Folosesc vectorul s ce reprezinta diagonala lui S pentru a sorta descrescator valorile proprii si retin in vectorul `poz` pozitia din vectorul nesortat a fiecarei valoare propriie. Folosind `poz` sortez matricea v astfel incat prima coloana sa fie vectorul propriu corespunzator celei mai mari valori proprii si asa mai departe, rezultatul este pus in V . Apoi urmez pasii 5, 6, 7 de la task 2.

Task 4

Functia `prepare_data` primeste ca argumente un tabel si numarul de imagini pe care vrem sa le extragem si folosind functia `load` incarca datele intr-o variabila din care salvez in `train_mat` primele `no_train_images` imagini si in `train_val` etichetele acestora.

Functia `visualise_image` primeste ca argumente matricea cu imagini si un numar si afiseaza imaginea cu indicele `number` din matrice. Folosesc functia `reshape` pentru a transforma imaginea dintr-un vector de lungime 784 intr-o matrice de 28 x 28.

Functia `magic_with_pca` calculeaza matricea de covariatie si spatiul k-dimensional al componentelor principale identic ca la task-ul 3. Apoi calculeaza proiectia imaginii in spatiul obtinut si in final calculeaza aproximatia imaginii.

Functia `prepare_photo` inverseaza imaginea, fiecare pixel devenind diferenta in modul dintre valoarea acestuia si 255. Apoi matricea de dimensiune 28 x 28 este transformata intr-un vector linie de lungime 784.

Functia `KNN` calculeaza distanta euclidiană dintre fiecare linie a matricei `Y` (imaginile vectorizate) si vectorul de test. Apoi sortez crescator distantele obtinute si retin pozitiile din vectorul initial pentru fiecare valoare si extrag etichetele pentru primele `k` (= 5) imagini. Folosind functia `median` pe vectorul de etichete calculat obtin predictia.

Functia `classify_image` pune cap la cap functiile precedente din task 4. Apeleaza `magic_with_pca` pe setul de antrenamente, scade din imagine (sub forma de vector) media fiecărei coloane din `train_mat` (miu obtinut la `magic_with_pca`), schimba baza imaginii (spatiul obtinut la `magic_with_pca`) si aplica KNN pentru valorile obtinute (`train_val` = etichetele imaginilor, `Y` = proiectia imaginilor de antrenament in spatiul componentelor principale, `test` = imaginea in noua baza si `k` = 5 (numarul de imagini pe care le cautam)), obtinand in final predictia.